

סנטינל סטייה דו-מצעי

ניטור מאוחד של מפעיל אנושי ושכבת סוכני AI תחת מודל כשל אחד

מענה לקול קורא, מנהלת ה-AI והאוטונומיה, מפא"ת

פער מבצעי ראשי: הגנה על הגבולות (#1) | משני: תומכי החלטות (#5)

נושא טכנולוגי: ארכיטקטורת AI וסוכנים (#3) | סיווג המסמך: בלמ"ס

מוגש על ידי: COR-SYS בשותפות עם Data For Business

א. רקע על המציע ופרטי יצירת קשר

המענה מוגש בשותפות בין שני גורמים. COR-SYS אחראית על הקונספט, המודל המתמטי וקניין הרוחני. Data For Business מביאה את ההובלה המערכתית, ההיכרות עם הסביבה הביטחונית, והיכולת הארגונית למימוש.

COR-SYS, מקור הקונספט. פרקטיקה הפועלת בצומת של מדעי ההתנהגות, מערכות ארגוניות והנדסת מערכת. הליבה המתודולוגית מבוססת על תורת שימור המשאבים (Conservation of Resources) ועל התערבות מבנית במערכות אנושיות תחת לחץ. מוביל: ארז טל-שיר, עובד סוציאלי טכנולוגי. אחראי על מודל הסף, שיטת ה-NOD-Sentinel, וההנדסה הטכנית של המכשיר.

Data For Business, שותף מימוש. חברה המתמחה בתהליכים עסקיים מבוססי דאטה, ניהול ידע וטרנספורמציה דיגיטלית. הצוות משלב ניסיון מערכתי-ביטחוני עמוק:

- ניקולס בנדורק, מנכ"ל ומייסד. סגן אלוף במיל', 24 שנות שירות בצה"ל בפיתוח תהליכים ומערכות מידע.
- גרמן גילטמן, סמנכ"ל תפעול. אלוף משנה במיל', 30 שנות שירות בתפקידי פיקוד בכירים, סגן מפקד אוגדה ומח"ט בשריון.
- אילון לוי, מומחה מערכות מידע. 23 שנות שירות, רובן במערך התקשוב, ראש ענף הדיגיטל של זרוע הים בתפקידו האחרון.
- שי פרוכטמן, CDO. כ-20 שנה בניהול ידע ותהליכים, פיתוח מוצרים עבור פיקוד העורף, המל"ל ומשרד הבריאות בעולמות HLS.

חלוקת היכולות: Data For Business מביאה את ההיכרות עם הסביבה המבצעית, ההובלה המערכתית, והנגישות לגופי הביטחון. ההנדסה הטכנית של הסנטינל מובלת על ידי COR-SYS. שכבת המימוש ההנדסי של אבני הדרך M1 עד M3 מוגדרת בתכנית העבודה ותתוגבר לפי הצורך.

איש קשר: [שם] **דוא"ל:** [להשלמה] **טלפון:** [להשלמה]

הרכב הצוות, על רקעו המערכתי-ביטחוני, נותן מענה לדרישות הכשירות והסיווג. הסדרת מעמד ספק פעיל וסיווג ביטחוני תושלם מול המשרד בהתאם לדרישות.

ב. הפער המבצעי (נספח א')

ראשי, סעיף #1 הגנה על הגבולות. הקול הקורא נוקב מילולית בעיוורון קשב (Alarm Fatigue), עומס קוגניטיבי, סינון רעש סנסורי, ומיקוד הקשב האנושי באירועי אמת קריטיים בלבד.

משני, סעיף #5 תומכי החלטות ותהליכים. המענה אינו מוסיף עוד התרעה לזרם. הוא מנהל את תקציב הקשב של המפעיל, מסנן לפי מצב עומס, ובמקביל מנטר את זרם ההחלטות של שכבת ה-AI לאיתור סחף שקט.

בשתי הזירות, האנושית והאלגוריתמית, הגרסה הקטלנית של הכשל שקטה. סף ההתרעה הנתפס נסחף מעל הסף האמיתי, והמערכת פועלת באזור הסתברות כשל מוגברת בלי שאף התרעה בודדת נדלקת. זו נורמליזציה של סטייה: חריגה שלא נענשה הופכת לנורמה ללא תיעוד.

ג. הנושא הטכנולוגי (נספח א')

ראשי, סעיף #3 ארכיטקטורת AI וסוכנים. תת-סעיף 3, ניטור סוכני AI בזמן אמת: שקיפות, זיהוי כשלים והבנת החלטות במהלך פעולה. תת-סעיף 4, מידור והרשאות בסביבת סוכנים.

נגיעה, הסברתיות (Explainability) והגברת אמון אנושי, תחת סנסורים סעיף 4: הצגת נימוקים והקשרים לצורך אישור פעולות רגישות.

ד. תיאור הפתרון

מכשיר אחד, שני מצעים מנוטרים, אותה מתמטיקת סטייה. האדם והמכונה מנוטרים באותו מודל כשל ומוצגים על מסך אחד באותה לוגיקת התרעה.

היחס המרכזי: J Quotient


$J = E / C$, עומס חלקי קיבולת. אצל המפעיל: קיבולת קוגניטיבית מול עומס סנסורי-משימתי. אצל הסוכן: תקציב החלטה וחישוב מול אנטרופיית קלט וסתירת מטרות. המערכת מודדת שתי כמויות נצפות: $J(t)$ רגעי מפרוקסי, ו- $G(t)$ זמני, פער ה-NOD, הקצב שבו הישות מקבלת חריגות בלי תיקון.

מנגנון 1: מעבר הפאזה הלוגיסטי

$P_{fail}(J) = 1 / (1 + \exp(-k(J - J^*)))$. הגיין המקומי dP/dJ מקסימלי בדיוק ב- J^* , ולכן שינוי קטן ב- J ליד הברך מקפיץ את הסתברות הכשל. הודגם נומרית: $\argmax$ השיפוע = 0.650, זהה ל- J^* שהוגדר, ושיא השיפוע $k/4 = 3.5$ תואם את התוצאה האנליטית (ראה נספח א', איור 1).

מנגנון 2: $G(t)$ כדיברגנס מצטבר


$G(t) \propto \sum D_{KL}(\text{behavior}(t) \parallel \text{baseline}) \cdot (1 - c(t))$, כאשר $c(t)$ מסמן אם הגיעה תוצאה מתקנת. הודגם על זרם החלטות סוכן מדומה בלקסיקון LangGraph, על האירועים {node, tool_call, retry, error}. עם החלקת EWMA, סף $\mu + 3\sigma$ מחלון בריא, ופרסיסטנס של 3 חלונות, האזעקה נדלקה במהלך הדריפט השקט, 34 חלונות לפני הקריסה. מוניטור שגיאות גולמי נדלק רק שני חלונות לפני הקריסה. הפער הזה הוא ההתרעה המוקדמת.



איור 1: $G(t)$ מזהה סחף שקט לפני קריסה. אזעקת ה-NOD ב- $t=66$, מוניטור גולמי רק ב- $t=98$, קריסה ב- $t=100$. הרצה מדומה, seed קבוע.

מנגנון 3: מצע כפול, מסך אחד

אותה לוגיקת J/G רצה על שני המצעים בו-זמנית. הודגם: מצע המפעיל חצה את J^* ב- $t=75$, מצע הסוכן ב- $t=81$, וחלון הכשל המורכב נפתח 19 חלונות לפני הקריסה. כששני המצעים חוצים יחד, מפעיל בעומס-יתר וסוכן בדריפט, זה מצב הכשל המסוכן ביותר במערכת אוטונומית עם אדם בלולאה.



איור 2: מודל אחד, שני מצעים, לוגיקת התרעה אחת. חלון הכשל המורכב מסומן לפני הקריסה.

הליכה המשותפת: הטופלה (C, E, J, J^* , G, P_fail) חסרת-מצע. אותן משוואות רצות על אדם ועל סוכן. זה הרכיב שאין לו מקביל בשוק, והוא החיבור בין ממשק אנושי פשוט לשליטה (#16) לבין ניטור סוכנים בזמן אמת (#3).

ה. תכנית עבודה ואבני דרך


כל אבן דרך עם שער מדיד. M1 ו-M2 נסגרו ברמת נתיב מימוש מתועד והדגמה. M3 ו-M4 הם הפיתוח והוולידציה התפעולית, בטווח של שנה עד שנתיים.

מבנה הביצוע: COR-SYS מובילה את ההנדסה הטכנית של הסנטינל. Data For Business מובילה את ההטמעה בסביבה המבצעית, ההיכרות עם הדרג המשתמש, והנגישות לגופי הביטחון הנדרשים לוולידציית M4.

שער מדיד	תוכן	אבן דרך
G מפיק הפרדה בת-משמעות על זרם חיצוני בלי rebuild. מודגם עקרונית (איור 1).	מיקוד מחדש מטלמטריה עצמית לזרם סוכן חיצוני. הסנטינל נרשם כ-subscriber פסיבי ל- astream_events / stream_mode של LangGraph, ללא עריכת internals.	M1
CI של J* שאינו כולל 0 ו-1, ו-AUC על held-out מעל סף. הודגם בפועל (איור 3).	כיול וולידציה. התאמת לוגיט ב-MLE על trajectories, שחזור J* ו-k, חישוב CI ו-AUC.	M2
הצגת שני המצעים תחת לוגיקת התרעה אחת, עם נימוק לכל אזעקה ובקרת הרשאות.	מסך מאוחד לשני המצעים, שכבת הסברתיות (Explainability) לאישור פעולה רגישה, ו-RBAC למידור והרשאות.	M3
שחזור פרמטרים על דאטה אמת, לא מדומה, ועמידה בקריטריון M2 בשדה.	ולידציה מייצגת-שדה על מערכת רב-סוכנים תפעולית.	M4

השער של M2 הורץ בפועל על דאטה שנדגם מלוגיסטיק ידוע, כהוכחת שיטת השחזור. J* אמת 0.62 שחזור כ-0.628, רווח סמך 95% [0.618, 0.639] שאינו כולל את הקצוות, ו-AUC על held-out = 0.96.

Demo 4 — M2 milestone gate executed: J* and k recovered from data with CI and AUC



איור 3: שער M2 בפועל. שחזור פרמטרים עם רווח סמך משמאל, הפרדה על held-out מימין. דאטה סינתטי לאימות השיטה, ולידציית שדה היא M4.

ו. אומדן עלויות

המבנה לפי אבני דרך עם הנחות עבודה מפורשות. הספרות הכספיות יושלמו על ידי המציע בהתאם להיקף ולתנאי ההתקשרות.

עלות	הנחות עבודה	אבן דרך
[להשלמה]	אינטגרציה מול פריסת LangGraph קיימת. ללא חומרה חדשה. מול stack observability סטנדרטי.	M1
[להשלמה]	איסוף ותיגוג של N trajectories, חישוב סטטיסטי. ללא חומרה ייעודית.	M2
[להשלמה]	פיתוח ממשק מאוחד, שכבת הסברתיות ו-RBAC.	M3
[להשלמה]	גישה למערכת רב-סוכנים תפעולית וסביבת ניסוי לוולידציה.	M4

שמירת מידע בסביבה: הטלמטריה מנותבת ל-LangSmith בפריסה עצמית (self-hosted / BYOC) או ל-OTel collector עצמאי, כך שנתוני המעקב אינם יוצאים מהסביבה. רלוונטי להקשר בלמ"ס.

ז. ייחודיות הפתרון

מצע כפול, מודל כשל אחד. אף ספק אינו מנטר מפעיל וסוכן באותו מודל כשל ותחת אותו סף.

ניגוד למסגרות קיימות: LangGraph עם LangSmith, וכן AutoGen ו-CrewAI, מנטרים execution-trace, כלומר latency, שגיאות ו-token usage. הם אינם מודדים סחף NOD שקט מול baseline, ואינם ממסגרים את המפעיל האנושי באותה לוגיקה. הם תשתית הזרם שעליה הסנטינל יושב, לא תחליף לו.


בציר הכיול, המסגרות הקיימות מדווחות מה שכבר קרה. הסנטינל מנבא התקרבות שקטה לסף לפני שהיא מתפרצת. NOD הוא קונסטרקט ניטור על בסיס מדעי-התנהגותי.

פטנטים: אין כרגע, מצוין בכנות. מודל הסף ושיטת ה-NOD-Sentinel הם IP בר-הגנה.

נספח א': בסיס אמפירי ושיטת ההדגמה

המנגנון הלוגיסטי, הוכחה מתמטית

הנגזרת של פונקציה לוגיסטית מקסימלית בנקודת הפיתול, שם הפונקציה שווה לחצי הטווח. מכאן ש- dP/dJ מקסימלי בדיוק ב- J^* . הודגם נומרית: argmax השיפוע על רשת צפופה = 0.650, זהו ל- J^* שהוגדר.



איור א-1: הגיין המקומי dP/dJ מקסימלי בדיוק ב- J^* .

J^* כהשערה הניתנת לכיול, טווח נתמך 0.4 עד 0.8

- תורת תורים: ברך זמן התגובה עולה בתלילות סביב ניצולת 0.65 עד 0.8, תלוי קריטריון. זה האנלוג הקרוב ביותר ליחס קריטי.
- עומס קוגניטיבי, redline של SWAT סביב 0.4 מנומל (Reid & Colle, 1988). מצביע על סף מוקדם יותר, שמרני.
- Yerkes-Dodson (1908): האופטימום באמצע הטווח ויורד ככל שהמשימה קשה יותר.
- מסקנה: 0.65 הוא אמצע סביר, לא קבוע. הוא מכויל לכל מצע ב-M2, ולא נקבע מראש.

הקפיצה פי כ-4 ("300%")

אין עוגן מחקרי בודד למכפיל נקי. הוא נשלט על ידי תלילות k וחלון המדידה, כלומר תכונה נגזרת של שני פרמטרים מותאמים, לא קבוע עצמאי. נוסח ככזה.

האטה קריטית כאיתות מוקדם

עליית שונות ואוטוקורלציה הן מבשרים גנריים למעברים קריטיים (Scheffer et al., Nature 461:53-59, 2009; Dakos et al., PNAS 105:14308, 2008). תומך בהוספת מדדי שונות ואוטוקורלציה לצד סף ה- J .

תורת גילוי אותות ועיוורון קשב

הרגישות 'd' והקריטריון נסחפים תחת עומס, הבסיס הפורמלי ל-Alarm Fatigue. במחקר תצפיתי, 88.8% מאזעקות הקצב היו שווא (Drew et al., PLOS ONE, 2014). סקירה שיטתית מצאה 72% עד 99% אזעקות שווא או לא-רלוונטיות (Frontiers in Digital Health, 2022).

נורמליזציה של סטייה

הניסוח המקורי של Vaughan על אסון צ'לנג'ר (The Challenger Launch Decision, 1996). הרקורסיה $J_{\text{alarm}}(t+1) = J_{\text{alarm}}(t) + \alpha \cdot \delta(t) \cdot (1 - c(t))$ היא פורמליזציה נאמנה של חריגה שמתקבלת כשאינה נענשת.

דיברגנס KL כמדד סחף

שיטות זיהוי סחף ומוניטורינג מבוססות KL מבוססות ומתוקפות בספרות (Basterrech & Woźniak, 2022), ומבססות את $G(t) \propto \sum D_{\text{KL}}(\text{behavior} \parallel \text{baseline})$

שקיפות שיטת ההדגמה

ההדגמות הורצו ב-Python עם seed קבוע. איורים 1 ו-2 מבוססים על זרם החלטות מדומה שמחקה לקסיקון אירועים של LangGraph. איור 3 (כיוול M2) מבוסס על דאטה סינתטי שנדגם מלוגיסטיק ידוע, כדי לתקף את שיטת השחזור. ולידציה על מערכת חיצונית חיה היא M4.